

F2 - Classical Search

SQL exacto, filtros estructurados, FTS5 y BM25

Documento de aprendizaje y referencia técnica

Estado de la fase

F2 validada con el corpus real de SAT: 3.249 KnowledgeItems indexados, 16 tests verdes y un primer dataset semilla de evaluación con Recall@5 = 1.000 y MRR = 1.000. Estas métricas se interpretan como validación del pipeline, no como prueba de suficiencia general de BM25.

Elemento	Valor
Proyecto	Applied Knowledge Lab (AKLab)
Fase	F2 - Búsqueda clásica
Versión	0.2.0
Corpus real	Gredos SAT
KnowledgeItems	3.249
Tecnología de búsqueda	SQLite FTS5 + BM25
Tests	16 passed

1. Qué pretende enseñar F2

F2 establece un baseline clásico antes de incorporar técnicas semánticas o generativas. El objetivo no es demostrar que la búsqueda lexical sea suficiente, sino medir qué puede resolver una solución tradicional y conservar ese resultado como punto de comparación para las fases posteriores.


- Distinguir búsqueda exacta, filtrado estructurado y búsqueda textual.
- Entender qué aporta un índice invertido frente a recorrer tablas con SQL.
- Entender BM25 como función de ranking lexical, no como búsqueda semántica.
- Introducir evaluación reproducible con Recall@K y MRR.
- Crear un baseline que permita medir posteriormente embeddings, hybrid search, reranking o query rewriting.

Regla pedagógica

Una técnica nueva sólo es interesante si podemos comparar su resultado con algo anterior. F2 crea ese punto de referencia.

2. Arquitectura de la búsqueda clásica

El conocimiento continúa almacenado en el modelo canónico. FTS5 es una representación derivada y regenerable, igual que más adelante lo serán los embeddings.



Esta separación es deliberada: el índice no es la base de conocimiento. Puede borrarse y reconstruirse sin perder la información original ni sus evidencias.

3. Tres tipos de búsqueda que no deben confundirse

Tipo	Ejemplo	Fortaleza	Limitación
------	---------	-----------	------------

Exacta	error_code = 15002	Precisión máxima cuando el dato está estructurado	No resuelve expresiones alternativas
Filtros	kind=support_case, module=Compras	Reduce el espacio de búsqueda con reglas explícitas	Necesita metadatos conocidos
FTS/BM25	"precio medio compras"	Ordena documentos por coincidencia lexical relevante	No entiende por sí mismo equivalencias semánticas

4. Qué es FTS5

FTS5 es el motor de búsqueda de texto completo integrado en SQLite. Construye un índice invertido: en lugar de recorrer cada documento para cada consulta, mantiene una estructura que permite localizar rápidamente qué documentos contienen cada término.

consulta: "precio medio compras"

índice invertido:

precio -> docs 6, 219, ...

medio -> docs 6, 2030, ...

compras -> docs 6, 219, ...

El índice de F2 incorpora texto procedente del título, resumen, contenido, secciones y atributos del KnowledgeItem. De esta forma busca sobre la representación normalizada, no directamente sobre SAT.mdb.

5. Qué es BM25

BM25 es una función de ranking lexical. No genera significado ni embeddings. Su función es ordenar los documentos recuperados según la relevancia de los términos de la consulta.

- Un término raro suele aportar más información que uno que aparece en casi todos los documentos.
- Repetir muchas veces una palabra no incrementa indefinidamente la relevancia.
- La longitud del documento se normaliza para evitar favorecer automáticamente textos muy largos.
- Los campos pueden ponderarse de forma diferente; en AKLab el título y los atributos reciben señales más fuertes que texto narrativo secundario.

Importante

BM25 trabaja con palabras y frecuencias. Si una consulta y un documento expresan la misma idea con vocabulario muy distinto, puede no recuperarlos bien. Ese problema será central cuando estudiemos embeddings.

6. Flujo de indexación en AKLab

1. Se importa o crea un KnowledgeItem.
2. El sistema compone un documento de búsqueda a partir de campos normalizados.
3. SearchIndexer actualiza la representación FTS5.
4. SearchService ejecuta MATCH y ranking BM25.
5. Los filtros estructurados se aplican cuando corresponden.
6. El índice puede reconstruirse completamente mediante el script de reindexación.

La segunda importación completa de SAT volvió a procesar 13.618 SourceItems sin crear KnowledgeItems nuevos y dejó 3.249 elementos indexados. Esto confirma que la búsqueda se mantiene compatible con la idempotencia construida en F0.2.

Validación de importación	Resultado
Primera importación	13.618 nuevos; 3.249 KnowledgeItems; 3.249 indexados
Segunda importación	13.618 unchanged; 0 KnowledgeItems nuevos; 3.249 indexados

7. Primer dataset de evaluación

F2 introduce un dataset semilla pequeño y explícito. Cada caso contiene una consulta y el KnowledgeItem que esperamos recuperar. El propósito inicial es validar el bucle de evaluación, no representar todavía toda la dificultad real del dominio.

Caso	Consulta	Esperado	Resultado
1	Error 75 Windows 95	CONSULTAS:1	Top-1
2	corchetes formula seleccion	CONSULTAS:3	Top-1
3	configuracion impresora conta 2000	CONSULTAS:4	Top-1
4	Alt F2 articulo pedido cliente	CONSULTAS:5	Top-1
5	precio medio compras	CONSULTAS:6	Top-1

8. Métricas: Recall@K y MRR

8.1 Recall@K

Pregunta: ¿hemos recuperado los documentos relevantes dentro de los primeros K resultados? En este dataset cada caso tiene un único documento esperado, por lo que Recall@5 vale 1 cuando el documento aparece en las cinco primeras posiciones.

$$\text{Recall@5} = \frac{\text{documentos relevantes recuperados en top 5}}{\text{documentos relevantes esperados}}$$

8.2 MRR

Mean Reciprocal Rank premia que el primer resultado relevante aparezca cuanto antes. Si aparece primero, RR = 1. Si aparece segundo, RR = 1/2; tercero, 1/3, etc. MRR es la media entre todos los casos.

$$\text{RR} = 1 / \text{posicion_del_primer_resultado_relevante}$$
$$\text{MRR} = \text{media}(\text{RR de todos los casos})$$

9. Resultado real de F2

Métrica	Resultado
Casos evaluados	5
Recall@5 medio	1.000
MRR	1.000
Posición del esperado	Top-1 en los 5 casos

Cómo interpretar 1.000 / 1.000

El resultado confirma que FTS5, el ranking, el dataset y el evaluador funcionan conjuntamente. No demuestra que BM25 entienda todas las preguntas de soporte ni que sea mejor que técnicas semánticas. Las cinco consultas utilizan vocabulario cercano al contenido original, por lo que constituyen un baseline favorable y deliberadamente sencillo.

10. Qué todavía NO resuelve F2

- Sinónimos y paráfrasis alejadas del vocabulario almacenado.
- Preguntas vagas como "no me funciona la factura" cuando el documento relevante usa otra terminología.
- Relaciones conceptuales entre errores, parámetros, módulos y procedimientos.
- Desambiguación mediante contexto conversacional.
- Reescritura o expansión automática de consultas.
- Similitud semántica mediante embeddings.
- Respuesta generativa basada en evidencias recuperadas.

Estas limitaciones no son defectos accidentales de F2: son el terreno experimental que permitirá demostrar qué aportan las fases siguientes.

11. Cómo mejorar el dataset sin cambiar el buscador

Antes de concluir que necesitamos una técnica más compleja, el dataset debe crecer. Un buen conjunto de evaluación debería mezclar distintos niveles de dificultad.

Nivel	Ejemplo	Qué prueba
Fácil	"Error 75 Windows 95"	Coincidencia lexical directa
Medio	"problema al entrar desde otro equipo con Windows"	Paráfrasis parcial
Difícil	"otra terminal ya está dentro y me expulsa"	Mismo síntoma con vocabulario distinto
Adversarial	consulta con términos de varios casos similares	Capacidad de discriminación

12. Decisiones arquitectónicas consolidadas

- El índice de búsqueda es una proyección regenerable del conocimiento.
- Las fuentes originales y Evidence continúan siendo la autoridad de trazabilidad.
- FTS5/BM25 es el baseline, no una dependencia conceptual del dominio.
- La búsqueda manual y la importada utilizan el mismo modelo canónico.
- Las métricas forman parte del producto experimental desde esta fase.
- No se introduce IA antes de tener una referencia medible.

13. Comandos de referencia

Comprobar FTS5:

```
python scripts/check_search_capabilities.py
```

Reconstruir índice:

```
python scripts/rebuild_search_index.py <database.sqlite>
```

Evaluar baseline:

```
python scripts/evaluate_search_baseline.py <database.sqlite> experiments/f2-baseline/gredos-seed.jsonl --k 5
```

Ejecutar tests:

```
python -m pytest -q
```

14. Estado al cerrar F2

Componente	Estado
Modelo canónico	Activo
Ingesta SAT	Validada
CRUD manual	Validado
KnowledgeRevision	Activo
FTS5	Disponible
BM25	Activo
Filtros estructurados	Activos
Evaluación Recall@K / MRR	Activa
Embeddings	No implementados
RAG	No implementado
LLM en retrieval	No utilizado

15. Próxima fase

Según el roadmap original, F3 introduce Structured Outputs: intent classification, extracción de entidades y clasificación de preguntas. La comparación interesante será observar cuánto mejora la interpretación de una consulta antes de modificar el motor de recuperación semántica.

Punto de referencia conservado

F2 queda como baseline clásico. Cuando lleguen embeddings, hybrid search o reranking, la pregunta ya no será "¿parece mejor?", sino "¿mejora Recall@K, MRR o la calidad final sobre los mismos casos y a qué coste?"